ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO
LAB 2 – MODELING

Giảng viên hướng dẫn: Huỳnh Lâm Hải Đăng
Môn học: Nhập môn khoa học dữ liệu
Họ và tên sinh viên: Lê Hà Thanh Chương
Mã số sinh viên: 23120195

Thành phố Hồ Chí Minh, tháng 1 năm 2026

MỤC LỤC

A. TỔNG QUAN **4**

B. HIERARCHICAL PARSING **4**

I. MULTI-FILE HANDLING 4

1. Gom nhóm và phân giải nội dung theo cơ chế đệ quy 5

2. Nhận diện tệp chính 5

II. HIERARCHY CONSTRUCTION 5

1. Mô hình hóa cấu trúc tài liệu 6

2. Thuật toán xây dựng cây dựa trên ngăn xếp 6

III. STANDARDIZATION 6

1. Làm sạch văn bản và giảm nhiễu 7

2. Chuẩn hóa biểu thức toán học 7

IV. DEDUPLICATION STRATEGY 7

1. Reference Entries Deduplication 7

2. Full-text Cross-version Deduplication 8

C. REFERENCE MATCHING PIPELINE **8**

I. DATA PREPARATION 8

1. Labelling Strategy 9

2. Data Splitting 9

II. FEATURE ENGINEERING 10

1. Nhóm đặc trưng văn bản 10

2. Nhóm đặc trưng Metadata (Bibliographic Features) 11

3. Nhóm đặc trưng ID và Định danh 11

4. Phân tích khả năng phân loại của đặc trưng 12

III. MODELING 12

1. Lựa chọn thuật toán 12

2. Quy trình huấn luyện và Cấu hình tham số 13

C. THỰC NGHIỆM VÀ KẾT QUẢ **14**

I. PARSER PERFORMANCE 14

1. Thống kê độ ổn định 14
2. Hiệu quả nén dữ liệu 15
II. REFERENCE MATCHING PIPELINE 16
1. Evaluation Metric 16
2. Cấu hình thực nghiệm 16
3. Kết quả định lượng 16
4. Đánh giá khả năng mở rộng 17
D. THỰC HÀNH – DEMO 17

A. TỔNG QUAN

Sự gia tăng theo cấp số nhân của các công bố khoa học trên nền tảng lưu trữ mở như arXiv đang thúc đẩy mạnh mẽ nhu cầu khai phá tri thức tự động, phục vụ các bài toán cốt lõi như tóm tắt văn bản, xây dựng đồ thị tri thức và phân tích xu hướng nghiên cứu. Mặc dù mã nguồn LaTeX là tiêu chuẩn của cộng đồng học thuật nhờ sự phong phú về mặt cấu trúc, định dạng này lại đặt ra thách thức nghiêm trọng cho quá trình xử lý máy tính do tính phân mảnh đa tập tin, mức độ nhiễu cú pháp cao và thiếu tính chuẩn hóa. Xuất phát từ rào cản thực tiễn đó, đồ án này tập trung xây dựng một hệ thống xử lý dữ liệu đầu cuối nhằm chuyển đổi mã nguồn LaTeX thô của bài báo khoa học thành dữ liệu có cấu trúc phân cấp chuẩn hóa, đồng thời giải quyết bài toán khớp nối các trích dẫn tham khảo với cơ sở dữ liệu arXiv thực tế.

Hệ thống được cấu trúc thành hai phân hệ độc lập nhưng liên kết chặt chẽ. Phân hệ thứ nhất, phân tích cấu trúc (Hierarchical Parsing), ứng dụng thuật toán duyệt đồ thị đệ quy và phân tích ngăn xếp để hợp nhất tài liệu, loại bỏ nhiễu định dạng, từ đó tái tạo tài liệu dưới dạng cây phân cấp JSON chuẩn hóa về mặt ngữ nghĩa. Đặc biệt, chiến lược lưu trữ định vị nội dung (Content-Addressable Storage) dựa trên mã băm MD5 được triển khai nhằm khử trùng lặp chéo phiên bản, giúp tối ưu hóa không gian lưu trữ và tăng tốc độ tính toán.

Trên nền dữ liệu này, một quy trình học máy được xây dựng thông qua phân hệ thứ hai, khớp nối tham chiếu (Reference Matching), giải quyết tình trạng nhập nhằng và không nhất quán trong trích dẫn khoa học. Bằng cách mô hình hóa dưới dạng bài toán học xếp hạng (Pointwise Learning to Rank), kết hợp chiến lược học giám sát yếu (weak supervision) và thuật toán Gradient Boosting Classifier, hệ thống có khả năng truy hồi chính xác định danh arXiv cho các truy vấn BibTeX nhiễu. Mục tiêu của đồ án là phát triển một hệ thống tự động, có khả năng mở rộng, đạt hiệu năng cao trên tập dữ liệu gán nhãn thủ công và duy trì tính ổn định khi vận hành trên quy mô lớn, qua đó mô phỏng đầy đủ quy trình của một bài toán Data Science hiện đại từ xử lý dữ liệu đến mô hình hóa và đánh giá.

B. HIERARCHICAL PARSING

I. MULTI-FILE HANDLING

Trong thực tế, các công bố LaTeX khoa học hiếm khi tồn tại dưới dạng một tệp đơn lẻ, mà thường được chia nhỏ thành nhiều module để thuận tiện cho việc biên soạn và quản lý. Do đó, để đảm bảo việc trích xuất nội dung được đầy đủ và nhất quán, bài làm triển khai một cơ chế xử lý đa tập tin có khả năng tự động phát hiện, liên kết và hợp nhất toàn bộ các tệp liên quan.

1. Gom nhóm và phân giải nội dung theo cơ chế đệ quy

Toàn bộ các tệp LaTeX trong thư mục được mô hình hóa như một đồ thị có hướng, trong đó mỗi tệp là một đỉnh và các lệnh chèn nội dung (như \input và \include) đóng vai trò là các cạnh liên kết. Hệ thống áp dụng chiến lược duyệt theo chiều sâu để lần lượt mở rộng nội dung từ tệp gốc sang các tệp phụ, nhằm tạo ra một chuỗi văn bản liền mạch duy nhất.

Cụ thể, hệ thống sử dụng regular expression để phát hiện các chỉ thị chèn nội dung phổ biến trong LaTeX, bao gồm cả các biến thể cú pháp có hoặc không khai báo phần mở rộng tệp. Mỗi khi phát hiện một chỉ thị như vậy, hàm đọc tệp được gọi một cách đệ quy để nạp nội dung tương ứng. Để tránh các vòng lặp vô hạn do tham chiếu chéo giữa các tệp, hệ thống duy trì một danh sách các tệp đã được xử lý. Nếu một tệp đã xuất hiện trước đó, nó sẽ được bỏ qua trong các lần gọi tiếp theo.

Nội dung của mỗi tệp con sau khi được đọc sẽ thay thế trực tiếp vị trí của chỉ thị gọi trong tệp cha. Quá trình này tiếp diễn cho đến khi toàn bộ đồ thị được duyệt xong, kết quả là một văn bản hợp nhất duy nhất sẵn sàng cho bước phân tích cú pháp tiếp theo.

2. Nhận diện tệp chính

Trong nhiều trường hợp, thư mục dự án có thể chứa hàng chục tệp LaTeX, và không có quy ước đặt tên thống nhất để xác định tệp nào là điểm bắt đầu. Thay vì dựa vào tên tệp một cách cứng nhắc, hệ thống sử dụng một cơ chế đánh giá dựa trên tập hợp các dấu hiệu cấu trúc thường xuất hiện trong tệp chính của tài liệu.

Mỗi tệp được gán một điểm số tổng hợp dựa trên sự hiện diện của các thành phần quan trọng như \documentclass, \begin{document}, hoặc các lệnh thiết lập cấu trúc tổng thể của bài viết (\maketitle, \tableofcontents, \bibliography…). Ngoài ra, một số tín hiệu phụ như tên tệp mang tính đại diện cũng được xem xét để tăng độ tin cậy. Ngược lại, các tệp có dấu hiệu là thành phần phụ trợ (appendix, chapter, section) sẽ bị trừ điểm nhằm hạn chế việc lựa chọn nhầm tệp gốc.

Tệp có điểm đánh giá cao nhất sẽ được chọn làm điểm khởi đầu cho toàn bộ quá trình phân giải đệ quy, đảm bảo rằng cấu trúc tài liệu được tái tạo theo đúng thứ tự logic mà tác giả ban đầu thiết kế.

II. HIERARCHY CONSTRUCTION

Sau khi hoàn tất việc hợp nhất nội dung từ nhiều tệp và làm sạch các thành phần cú pháp không cần thiết, hệ thống tiến hành chuyển đổi văn bản tuyến tính thu được thành một cấu trúc cây phản ánh tổ chức nội dung của tài liệu khoa học. Mục tiêu của bước này là bảo toàn mối quan hệ ngữ nghĩa giữa các phần, từ cấp độ tổng thể cho đến các đơn vị thông tin nhỏ nhất.

1. Mô hình hóa cấu trúc tài liệu

Toàn bộ tài liệu được biểu diễn dưới dạng một cây $T = (V, E)$, trong đó mỗi nút $v \in V$ đại diện cho một thành phần nội dung có ý nghĩa. Nút gốc tương ứng với toàn bộ tài liệu, trong khi các nút trung gian biểu diễn các cấp đề mục khác nhau, được sắp xếp theo độ sâu tăng dần dựa trên vai trò của chúng trong cấu trúc bài viết. Các cấp này bao gồm các phần lớn (part, chapter), mục chính (section), mục con (subsection, subsubsection) và các tiểu mục chi tiết hơn (paragraph, subparagraph).

Ở mức thấp nhất của cây là các nút lá, đại diện cho những đơn vị thông tin cơ bản như câu văn, phương trình, hình ảnh, bảng biểu hoặc các danh sách liệt kê. Việc tách câu được thực hiện cẩn trọng để tránh sai lệch trong các trường hợp đặc thù thường gặp trong văn bản khoa học, chẳng hạn như các chữ viết tắt hoặc ký hiệu chuyên ngành.

2. Thuật toán xây dựng cây dựa trên ngăn xếp

Do cấu trúc của tài liệu LaTeX mang tính lồng nhau rõ rệt, hệ thống sử dụng một thuật toán phân tích dựa trên ngăn xếp để duy trì ngữ cảnh hiện hành trong quá trình duyệt văn bản. Ban đầu, ngăn xếp chỉ chứa nút gốc. Khi hệ thống lần lượt đọc từng khối nội dung, nó sẽ xác định xem khối đó là một đề mục mới hay nội dung thông thường.

Khi gặp một đề mục mới, hệ thống so sánh cấp độ của đề mục này với cấp độ của nút đang nằm trên đỉnh ngăn xếp. Nếu đề mục mới có cấp độ không sâu hơn, điều đó cho thấy phạm vi của đề mục trước đã kết thúc. Khi đó, các nút không còn phù hợp sẽ lần lượt được loại khỏi ngăn xếp cho đến khi tìm được nút cha thích hợp. Nút đề mục mới sau đó được gắn vào cây và trở thành ngữ cảnh hiện hành.

Đối với các đoạn nội dung thông thường, hệ thống tạm thời lưu trữ chúng trong một bộ đệm. Khi gặp một ranh giới cấu trúc rõ ràng, bộ đệm này được xử lý, tách thành các đơn vị nhỏ hơn và gắn vào nút phù hợp trong cây. Cách tiếp cận này cho phép hệ thống xây dựng cây phân cấp một cách chính xác ngay cả trong các trường hợp tài liệu không tuân thủ chặt chẽ thứ bậc đề mục, đồng thời đảm bảo hiệu quả xử lý với độ phức tạp thời gian tuyến tính $O(N)$ (với N là độ dài văn bản).

III. STANDARDIZATION

Dữ liệu LaTeX thô chứa nhiều thành phần phục vụ mục đích trình bày hơn là nội dung, chẳng hạn như lệnh định dạng, khoảng trắng dư thừa hoặc chú thích. Những yếu tố này tạo ra nhiễu và làm giảm khả năng nắm bắt ngữ nghĩa của các mô hình phân tích dữ liệu. Do đó, module *LatexCleaner* được thiết kế nhằm chuyển đổi dữ liệu LaTeX sang dạng văn bản thuần, trong khi vẫn bảo toàn cấu trúc logic và các thực thể quan trọng như công thức toán học và trích dẫn.

1. Làm sạch văn bản và giảm nhiễu

Quy trình làm sạch được tổ chức thành một chuỗi các phép biến đổi tuần tự, với mục tiêu tối đa hóa thông tin hữu ích và loại bỏ các thành phần không mang giá trị ngữ nghĩa.

Trước hết, tất cả các dòng chú thích bắt đầu bằng ký tự %, cũng như chú thích nội dòng, được loại bỏ hoàn toàn. Thuật toán được thiết kế để không xóa nhầm các ký tự % đã được escape (\%), vốn có thể mang ý nghĩa nội dung.

Tiếp theo, các lệnh chỉ phục vụ cho việc dàn trang hoặc hiển thị, chẳng hạn như \newpage, \centering, \vspace, \hline, được loại bỏ vì không đóng góp vào nội dung học thuật. Song song với đó, các lệnh định dạng kiểu chữ như \textbf{...}, \textit{...} hay \emph{...} được đơn giản hóa bằng cách giữ lại phần nội dung bên trong. Ví dụ, \textbf{Hello} được chuyển thành Hello. Cách xử lý này giúp các từ khóa được biểu diễn thống nhất, không phụ thuộc vào cách trình bày ban đầu.

Cuối cùng, hệ thống chuẩn hóa khoảng trắng bằng cách nén các khoảng trắng dư thừa, tab và các dòng trống liên tiếp. Quy tắc được áp dụng là duy trì tối đa hai dòng trống để phân tách các đoạn văn, nhằm bảo toàn ranh giới đoạn khi thực hiện các bước xử lý ngôn ngữ tiếp theo.

2. Chuẩn hóa biểu thức toán học

Trong LaTeX, cùng một công thức toán học có thể được biểu diễn dưới nhiều hình thức khác nhau. Để đảm bảo tính nhất quán trong biểu diễn và trích xuất đặc trưng, hệ thống quy tất cả các biểu thức toán học về hai dạng chuẩn.

Đối với biểu thức toán học trên dòng, mọi biến thể như \(... \) đều được chuyển về dạng thống nhất $ ... $. Đối với khối biểu thức toán học, các biểu thức viết dưới dạng \[... \], $$ ... $$, cũng như các môi trường phức tạp như align, gather, multline hay eqnarray, đều được bao gộp lại thành môi trường chuẩn: \begin{equation} ... \end{equation}

IV. DEDUPLICATION STRATEGY

Dữ liệu thu thập từ arXiv có đặc thù là một bài báo có thể tồn tại dưới nhiều phiên bản khác nhau. Nếu không xử lý trùng lặp, việc lưu trữ và phân tích sẽ trở nên kém hiệu quả, đồng thời có nguy cơ làm sai lệch các thống kê tổng hợp. Để giải quyết vấn đề này, hệ thống áp dụng một chiến lược khử trùng lặp nhiều tầng, bao phủ cả mức độ tham chiếu và nội dung toàn văn.

1. Reference Entries Deduplication

Các mục tài liệu tham khảo là nền tảng cho việc xây dựng và phân tích mạng lưới trích dẫn. Module xử lý tham chiếu thực hiện việc hợp nhất thông tin dựa trên nội dung đã được chuẩn hóa của các trường

quan trọng như tiêu đề, tác giả và năm xuất bản. Mỗi mục tham chiếu (\bibitem hoặc BibTeX entry) được gán một mã băm (hashing); các mục có mã băm trùng nhau được coi là cùng một thực thể.

Khi phát hiện trùng lặp giữa các phiên bản, hệ thống chỉ giữ lại một bản ghi đại diện. Các trường thông tin còn thiếu sẽ được bổ sung từ phiên bản khác, trong khi những trường có sự khác biệt sẽ được cập nhật theo phiên bản mới hơn, với giả định rằng thông tin ở phiên bản sau đã được chỉnh sửa và chính xác hơn. Đồng thời, một bảng ánh xạ khóa trích dẫn được duy trì để liên kết các biến thể khác nhau của cùng một khóa tham chiếu về một định danh duy nhất, đảm bảo tính nhất quán trong toàn bộ tài liệu.

2. Full-text Cross-version Deduplication

Ở mức nội dung, hệ thống áp dụng một cơ chế lưu trữ dựa trên nội dung nhằm tối ưu hóa không gian và cho phép theo dõi sự thay đổi của văn bản qua các phiên bản. Trước khi so sánh, mỗi đơn vị nội dung như câu văn, hình ảnh hoặc công thức được chuẩn hóa mạnh bằng cách chuyển về chữ thường và loại bỏ dấu câu cùng khoảng trắng dư thừa. Cách làm này giúp các thay đổi nhỏ về hình thức không ảnh hưởng đến kết quả so sánh.

Sau đó, mỗi đơn vị nội dung được gán một mã băm bằng thuật toán MD5 để tạo ra một dấu nhận dạng duy nhất. Hệ thống duy trì một kho lưu trữ toàn cục cho các nội dung đã xuất hiện. Nếu một đoạn nội dung ở phiên bản mới có mã băm trùng với nội dung đã tồn tại, hệ thống không lưu trữ lại mà chỉ tạo liên kết tham chiếu đến nội dung gốc. Ngược lại, nếu nội dung có thay đổi, một định danh mới sẽ được sinh ra và bổ sung vào kho lưu trữ.

Cách tiếp cận này giúp giảm đáng kể dung lượng lưu trữ đối với các bài báo có nhiều phiên bản, đồng thời tạo ra một cấu trúc dữ liệu liên kết chặt chẽ.

C. REFERENCE MATCHING PIPELINE

Hệ thống khớp nối tham chiếu được xây dựng như một bài toán truy hồi và xếp hạng thông tin, trong đó mỗi trích dẫn BibTeX đóng vai trò là truy vấn đầu vào, còn mục tiêu của hệ thống là xác định và xếp hạng đúng ID arXiv tương ứng từ tập các ứng viên. Cách tiếp cận này cho phép mô hình xử lý hiệu quả sự không đồng nhất và thiếu chuẩn hóa thường gặp trong dữ liệu trích dẫn khoa học.

I. DATA PREPARATION

Dữ liệu được chuẩn bị thông qua chiến lược học có giám, kết hợp giữa dữ liệu gán nhãn thủ công và dữ liệu gán nhãn tự động quy mô lớn.

1. Labelling Strategy

a) Gán nhãn thủ công

Đây là bộ dữ liệu dùng để đánh giá hiệu năng thực tế của mô hình.

- **Quy trình:** Dựa trên cấu hình label.json, năm bài báo có số lượng trích dẫn lớn và cấu trúc đa dạng được lựa chọn để gán nhãn thủ công.
- **Danh sách bài báo:** 2412-18790, 2412-19279, 2412-19837, 2412-20155, 2412-20242.
- **Tiêu chí:** Mỗi bài báo được gán nhãn thủ công đảm bảo khớp nối chính xác (label = 1) cho ít nhất 20 cặp giữa BibTeX và arXiv.
- **Mục đích:** Sử dụng chủ yếu cho tập kiểm thử (Test) và tập xác thực (Validation) để đảm bảo độ tin cậy của kết quả đánh giá.

b) Gán nhãn tự động

Để tạo ra tập dữ liệu huấn luyện đủ lớn em áp dụng thuật toán gán nhãn dựa trên luật (Heuristic/Rule-based) cho 500 bài báo còn lại trong danh sách auto_subset.

Thuật toán DataLabeler tính toán điểm số tương đồng ($S_{heuristic}$) giữa BibTeX (B) và ArXiv metadata (A) dựa trên tổng trọng số của các đặc trưng trích xuất:

$$S_{heuristic} = w_1 \cdot Jaccard(Title) + w_2 \cdot SeqRatio(Title) + w_3 \cdot Overlap(Authors) + \cdots$$

Trong đó, cặp (B, A) được gán nhãn là *Positive (1)* nếu $S_{heuristic} \geq \tau$ (với ngưỡng $\tau = 0.7$). Các quy tắc heuristic chính bao gồm:

1. **Khớp chính xác:** Nếu tiêu đề trùng khớp 100% hoặc tìm thấy ArXiv ID trong chuỗi BibTeX thì điểm tin cậy = 1.0.
2. **Khớp mờ:** Sử dụng độ đo Jaccard (trên tập từ loại bỏ stopwords) và Sequence Matching Ratio cho tiêu đề.
3. **Khớp tác giả:** Kiểm tra sự trùng khớp của tên họ (Lastname) tác giả đầu tiên và độ bao phủ của danh sách tác giả.

2. Data Splitting

Dữ liệu được chia thành các Train, Valid và Test theo cách đảm bảo cả hai nguồn gán nhãn đều xuất hiện trong mỗi tập. Cụ thể, tập huấn luyện chủ yếu sử dụng dữ liệu tự động để tận dụng quy mô lớn, trong khi tập xác thực và kiểm thử mỗi tập đều chứa một bài báo được gán nhãn thủ công. Thiết kế này cho phép đánh giá hiệu năng mô hình trên dữ liệu chuẩn, đồng thời hạn chế nguy cơ mô hình học lệch theo các quy tắc gán nhãn tự động.

Tập dữ liệu (Partition)	Nguồn Manual	Nguồn Auto	Tổng số bài báo	Mục đích sử dụng
Training Set	3 bài	498 bài	**501**	Huấn luyện mô hình Ranker với lượng dữ liệu lớn.
Validation Set	1 bài	1 bài	**2**	Tinh chỉnh tham số và lựa chọn mô hình.
Test Set	1 bài	1 bài	**2**	Đánh giá độc lập hiệu năng cuối cùng.
TỔNG CỘNG	**5 bài**	**500 bài**	**505**	

II. FEATURE ENGINEERING

Trong bài toán *Reference Matching,* dữ liệu đầu vào chủ yếu là văn bản phi cấu trúc (Unstructured Text) từ các trường BibTeX (Title, Author, Venue...). Thách thức lớn nhất nằm ở sự không nhất quán về định dạng (ví dụ: *"J. Smith"* vs *"John Smith"*), lỗi chính tả, hoặc sự sai lệch về thời gian giữa bản Preprint (arXiv) và bản in chính thức (Published Version).

Để giải quyết vấn đề này, em đã xây dựng một bộ trích xuất đặc trưng (Feature Extractor) đa chiều, chuyển đổi các cặp văn bản (BibEntry, ArxivEntry) thành các vector số học chứa thông tin ngữ nghĩa và cấu trúc.

1. Nhóm đặc trưng văn bản

Đây là nhóm đặc trưng quan trọng nhất để so sánh tiêu đề bài báo (Title), nơi chứa mật độ thông tin định danh cao nhất.

Tên đặc trưng	Mô tả kỹ thuật	Biện luận
title_tfidf_cosine	Độ tương đồng Cosine trên vector TF-IDF (ngrams 1-2).	**Nắm bắt ngữ nghĩa toàn cục:** TF-IDF giúp giảm trọng số của các từ phổ biến không mang ý nghĩa (như "study", "analysis") và tăng trọng số cho các từ chuyên ngành hiếm gặp, giúp phân biệt các bài báo có tiêu đề chung chung.
title_jaccard_nostop	Chỉ số Jaccard trên tập từ (tokens) đã loại bỏ stopwords.	**Bất biến với trật tự từ:** Tiêu đề BibTeX và arXiv đôi khi bị đảo vị trí từ ngữ. Jaccard đo lường độ chồng lấp tập hợp mà không quan tâm thứ tự, giúp xử lý tốt trường hợp này.

title_sequence_ratio	Sử dụng thuật toán difflib.SequenceMatcher (tương tự Levenshtein).	**Xử lý lỗi chính tả:** Khác với Jaccard (dựa trên từ), đặc trưng này hoạt động ở cấp độ ký tự, giúp phát hiện sự tương đồng ngay cả khi có lỗi đánh máy (typos) hoặc viết tắt.
title_bigram_overlap	Độ chồng lấp của các cặp từ liên tiếp (Bigrams).	**Bảo toàn ngữ cảnh cục bộ:** Giúp phân biệt các bài báo có cùng tập từ vựng nhưng khác ý nghĩa do trật tự sắp xếp (ví dụ: *"Learning to Rank"* vs *"Rank to Learning"*).

2. Nhóm đặc trưng Metadata (Bibliographic Features)

Nhóm này khai thác các thông tin thư mục bổ trợ để tăng độ tin cậy khi tiêu đề bị nhiễu hoặc trùng lặp.

- **Đặc trưng Tác giả (Author Matching):**
  - **Vấn đề:** Tên tác giả thường không nhất quán (Viết tắt F. Lastname vs Đầy đủ Firstname Lastname).
  - **Giải pháp:** Chuẩn hóa tên về dạng lastname và sử dụng author_lastname_overlap (tỷ lệ trùng khớp họ) và author_first_match (khớp tác giả đầu tiên).
  - **Biện luận:** Tác giả đầu tiên (First Author) thường là định danh mạnh nhất của một công trình nghiên cứu. Việc khớp đúng họ của tác giả đầu tiên là một tín hiệu dương tính mạnh mẽ (Strong Positive Signal).
- **Đặc trưng Thời gian (Temporal Features):**
  - **Đặc trưng:** year_diff (khoảng cách năm) và year_arxiv_before_pub (kiểm tra logic thời gian).
  - **Biện luận:** Các bản arXiv (Preprint) thường xuất hiện trước hoặc cùng năm với bản xuất bản chính thức. Đặc trưng year_arxiv_before_pub kiểm tra xem $0 \leq (Năm_Pub - Năm_Arxiv) \leq 2$ hay không, giúp loại bỏ các ứng viên trùng tên nhưng khác thời điểm (bài báo cũ/mới).

3. Nhóm đặc trưng ID và Định danh

Đây là các đặc trưng mang tính chất "Quy tắc", có độ chính xác gần như tuyệt đối nếu tồn tại.

- venue_has_arxiv_id & venue_arxiv_id_match: Kiểm tra xem trường journal hoặc venue trong BibTeX có chứa chuỗi ID arXiv hay không.

- key_has_arxiv: Kiểm tra xem khóa BibTeX (BibKey) có chứa ID arXiv không (một thói quen phổ biến khi trích dẫn).
- **Biện luận:** Đây là các "Short-cut features". Nếu các đặc trưng này có giá trị dương, xác suất khớp nối đúng gần như là 100%, giúp mô hình cây quyết định (Tree-based model) nhanh chóng phân nhánh và đưa ra dự đoán chính xác mà không cần xét duyệt kỹ văn bản.

4. Phân tích khả năng phân loại của đặc trưng

Trong quá trình huấn luyện mô hình Gradient Boosting (sẽ trình bày ở phần sau), em nhận thấy:

1. title_tfidf_cosine và title_sequence_ratio đóng vai trò chủ đạo trong việc lọc ứng viên (Candidate Filtering).
2. year_diff_normalized đóng vai trò là bộ lọc nhiễu (Noise Filter), giúp loại bỏ các bài báo trùng tên (homonyms) nhưng khác thời đại.
3. Nhóm đặc trưng ID (*_arxiv_id_match) tuy xuất hiện ít (thưa thớt) nhưng có độ lợi thông tin (Information Gain) cực lớn khi xuất hiện.

III. MODELING

Dựa trên bản chất của bài toán khớp nối tham chiếu là tìm kiếm ứng viên phù hợp nhất trong cơ sở dữ liệu lớn, em tiếp cận vấn đề theo hướng ***Pointwise Learning to Rank***. Cụ thể, bài toán xếp hạng được chuyển đổi thành bài toán phân loại nhị phân (Binary Classification), trong đó mô hình học cách dự đoán xác suất tương đồng giữa một cặp (BibEntry, ArXivEntry).

1. Lựa chọn thuật toán

Trong module ReferenceMatcherModel, em đã thực nghiệm và hỗ trợ ba kiến trúc mô hình khác nhau: *Logistic Regression*, *Random Forest*, và *Gradient Boosting*. Sau quá trình đánh giá thực nghiệm, Gradient Boosting Classifier được lựa chọn làm mô hình chủ đạo cho hệ thống (mặc định trong pipeline).

Lý do lựa chọn Gradient Boosting:

- **Xử lý biên quyết định phi tuyến:** Các đặc trưng như *Jaccard Similarity* hay *Year Difference* thường có mối quan hệ phức tạp, không tuyến tính với nhãn mục tiêu. Gradient Boosting, với bản chất là tập hợp các cây quyết định (Decision Trees), có khả năng nắm bắt các tương tác phi tuyến này tốt hơn các mô hình tuyến tính như Logistic Regression.

- **Khả năng xử lý dữ liệu hỗn hợp:** Dữ liệu đầu vào bao gồm cả biến liên tục (cosine similarity score) và biến nhị phân (boolean flags like venue_is_arxiv). Cây quyết định xử lý tốt loại dữ liệu hỗn hợp này mà không cần biến đổi phức tạp.
- **Hiệu suất xếp hạng (Ranking Performance):** Trong các bài toán Learning to Rank, các mô hình dựa trên Boosting (như XGBoost, LightGBM, hay GradientBoosting của Sklearn) thường xuyên đạt kết quả SOTA (State-of-the-art) nhờ khả năng tối ưu hóa hàm mất mát qua từng vòng lặp (boosting iterations).

2. Quy trình huấn luyện và Cấu hình tham số

Quy trình huấn luyện được thực hiện thông qua class ReferenceMatcherModel với các bước chuẩn hóa và tối ưu hóa cụ thể như sau:

a. Chuẩn hóa dữ liệu

Trước khi đưa vào mô hình, toàn bộ vector đặc trưng được chuẩn hóa bằng kỹ thuật Standard Scaling (StandardScaler):

$$z = \frac{x - \mu}{\sigma}$$

Việc đưa các đặc trưng về cùng một phân phối chuẩn (mean = 0, std = 1) là bước quan trọng giúp thuật toán hội tụ nhanh hơn và tránh việc các đặc trưng có biên độ lớn (như year_diff) lấn át các đặc trưng có biên độ nhỏ (như tfidf_cosine).

b. Cấu hình tham số

Mô hình GradientBoostingClassifier được khởi tạo với bộ tham số tối ưu hóa nhằm cân bằng giữa độ chính xác (Bias) và độ ổn định (Variance), tránh hiện tượng quá khớp (Overfitting) trên tập dữ liệu huấn luyện:

Tham số	Giá trị thiết lập	Giải thích ý nghĩa
n_estimators	**100**	Số lượng cây quyết định (weak learners) được xây dựng tuần tự. Số lượng 100 đủ lớn để mô hình học được các mẫu phức tạp nhưng không quá lớn để gây chậm quá trình suy diễn.
max_depth	**5**	Độ sâu tối đa của mỗi cây. Độ sâu 5 cho phép mô hình nắm bắt được các tương tác đặc trưng bậc cao (ví dụ: *Title khớp* **VÀ** *Năm lệch <= 1*).

learning_rate	**0.1**	Tốc độ học. Giá trị 0.1 giúp mô hình hội tụ ổn định, đóng góp của mỗi cây mới vào tổng thể được kiểm soát chừng mực.
subsample	**0.8**	**Stochastic Gradient Boosting:** Chỉ sử dụng 80% dữ liệu ngẫu nhiên để xây dựng mỗi cây. Kỹ thuật này giúp giảm phương sai (variance) và hạn chế overfitting hiệu quả.
random_state	**42**	Đảm bảo tính tái lập (reproducibility) của kết quả thực nghiệm.

c. Chiến lược suy diễn

Sau khi huấn luyện, mô hình không chỉ dự đoán nhãn 0/1 mà trả về xác suất thuộc lớp Positive ($\mathrm{P}(y = 1|X)$) thông qua hàm predict_proba.

- Với mỗi BibEntry đầu vào, hệ thống tính toán xác suất khớp nối với tất cả các ứng viên ArXivEntry.
- Danh sách ứng viên được xếp hạng giảm dần dựa trên điểm xác suất này.
- Top-K (mặc định K=5) ứng viên có điểm số cao nhất sẽ được trích xuất làm kết quả dự đoán cuối cùng.

Chiến lược này đảm bảo rằng ngay cả khi mô hình không chắc chắn tuyệt đối, các ứng viên tiềm năng nhất vẫn được đưa lên đầu danh sách, tối ưu hóa chỉ số MRR (Mean Reciprocal Rank).

C. THỰC NGHIỆM VÀ KẾT QUẢ

I. PARSER PERFORMANCE

Trong thực tế, các công bố LaTeX khoa học hiếm khi tồn tại dưới dạng một tệp đơn lẻ, mà thường được chia nhỏ thành nhiều module để thuận tiện cho việc biên soạn và quản lý. Do đó, để đảm bảo việc trích xuất nội dung được đầy đủ và nhất quán, bài làm triển khai một cơ chế xử lý đa tập tin có khả năng tự động phát hiện, liên kết và hợp nhất toàn bộ các tệp liên quan.

1. Thống kê độ ổn định

Hệ thống đã được chạy trên tập dữ liệu gồm 5.000 bài báo (từ ID 2412-15271 đến 2412-20270). Kết quả ghi nhận từ file log hệ thống như sau:

- **Tổng số bài báo đầu vào:** ~5.000 bài.
- **Xử lý thành công (Success):** ~4.989 bài.
- **Bỏ qua (Skipped):** 11 bài (Các bài báo thiếu nguồn TeX hoặc bị rút - Withdrawn).

- **Lỗi (Failed):** 0 bài.

Tỷ lệ thành công (Success Rate):

$$Success_Rate = \frac{4989}{5000} . 100\% \approx 99.78\%$$

Nhận xét: Tỷ lệ lỗi 0% chứng minh rằng các cơ chế xử lý ngoại lệ và các biểu thức chính quy (Regex) trong module LatexCleaner đã bao quát tốt các trường hợp cú pháp lạ của LaTeX. Các trường hợp bị bỏ qua (Skipped) chủ yếu do dữ liệu nguồn không đầy đủ, đúng như thiết kế lọc nhiễu của hệ thống.

2. Hiệu quả nén dữ liệu

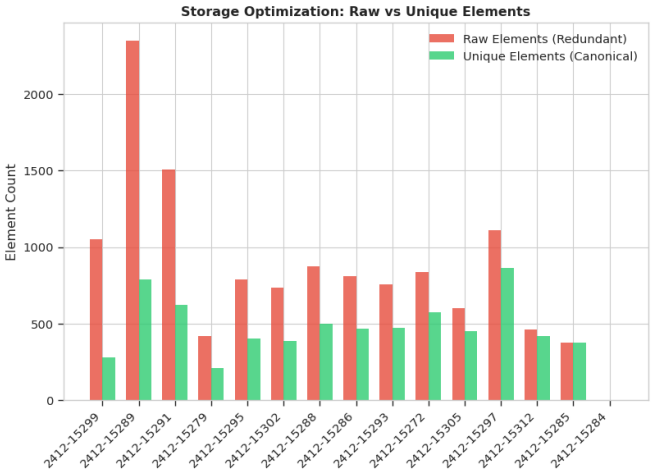

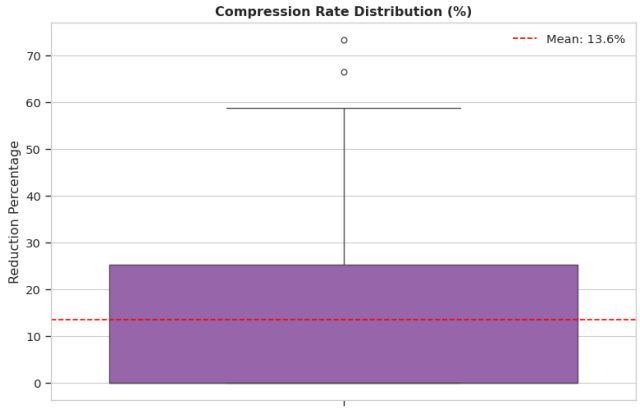

Để giải quyết vấn đề bùng nổ dữ liệu khi lưu trữ nhiều phiên bản (versions) của cùng một bài báo khoa học, hệ thống áp dụng cơ chế Content-Addressable Storage (CAS). Cụ thể, mỗi đơn vị nội dung (câu, đoạn văn, công thức) được định danh bằng mã băm MD5. Nếu nội dung không thay đổi giữa các phiên bản, hệ thống chỉ lưu trữ một bản ghi duy nhất và tạo tham chiếu liên kết.

Kết quả thực nghiệm trên tập dữ liệu mẫu (41 bài báo) ghi nhận các chỉ số ấn tượng:

- **Tổng số phần tử ngữ nghĩa (Raw Elements): 20,623** *(Bao gồm tất cả các câu, section, công thức từ mọi phiên bản)*
- **Số phần tử duy nhất (Unique Elements): 14,782** *(Số lượng thực tế được lưu trữ và xử lý)*
- **Số lượng phần tử được loại bỏ: 5,841**
- **Hiệu suất nén trung bình: ~13.6%** (trên toàn tập)
    - *Đặc biệt:* Với các bài báo có lịch sử cập nhật dày (như 2412-15299 với 4 versions), tỷ lệ nén đạt tới **73.38%**.

Nhận xét và Đánh giá tác động:

1. **Tối ưu hóa Tài nguyên Lưu trữ:** Việc loại bỏ gần 6.000 phần tử dư thừa giúp giảm tải đáng kể dung lượng ổ cứng, đặc biệt quan trọng khi mở rộng hệ thống lên quy mô hàng triệu bài báo (như ArXiv dump).
2. **Tăng tốc độ tính toán hạ nguồn (Downstream Acceleration):** Đây là lợi ích quan trọng nhất. Trong giai đoạn *Reference Matching* kế tiếp, mô hình máy học chỉ cần thực hiện dự đoán (Inference) trên 14,782 phần tử duy nhất thay vì toàn bộ 20,623 phần tử thô. Điều này đồng nghĩa với việc **giảm ~28% khối lượng tính toán** cho mô hình, giúp hệ thống vận hành nhanh hơn và tiết kiệm chi phí GPU/CPU.
3. **Bảo toàn tính toàn vẹn:** Mặc dù nén dữ liệu, cấu trúc cây phân cấp (Hierarchy Tree) của từng phiên bản vẫn được giữ nguyên thông qua cơ chế tham chiếu (linking), đảm bảo người dùng vẫn có thể truy xuất chính xác nội dung của một phiên bản cụ thể bất kỳ.

II. REFERENCE MATCHING PIPELINE

1. Evaluation Metric

Để đánh giá hiệu năng của mô hình xếp hạng, em sử dụng chỉ số Mean Reciprocal Rank tại k=5 (MRR@5). Đây là độ đo tiêu chuẩn trong các bài toán Information Retrieval, ưu tiên việc đưa kết quả đúng lên các vị trí đầu tiên trong danh sách gợi ý.

$$\text{MRR@}k = \frac{1}{|Q|}\sum_{i=1}^{|Q|}\frac{1}{\text{rank}_i}$$

Trong đó, rank_i là thứ hạng của bài báo arXiv chính xác trong danh sách 5 ứng viên được mô hình dự đoán.

2. Cấu hình thực nghiệm

- **Mô hình:** Gradient Boosting Classifier (với n_estimators = 100, learning_rate = 0.1).
- **Tập dữ liệu kiểm thử (Test Set):** Sử dụng các bài báo được gán nhãn thủ công (Manual Labels) để đảm bảo tính khách quan.
- **Tập dữ liệu quy mô lớn (Batch):** 500 bài báo được gán nhãn tự động.

3. Kết quả định lượng

Kết quả thực nghiệm được ghi nhận qua hai pha chạy: Kiểm thử trên Notebook (Development Phase) và Chạy hàng loạt trên Colab (Production Phase).

```
2026-01-18 13:02:16,654 - INFO - Saved predictions to /content/drive/MyDrive/ColabProject_5000/23120195/process1/2412-16344/pred.json
2026-01-18 13:02:16,669 - INFO - Saved predictions to /content/drive/MyDrive/ColabProject_5000/23120195/process1/2412-16345/pred.json
2026-01-18 13:02:16,697 - INFO - Saved predictions to /content/drive/MyDrive/ColabProject_5000/23120195/process1/2412-16346/pred.json
2026-01-18 13:02:16,697 - INFO - ==================================================
2026-01-18 13:02:16,697 - INFO - Validation MRR@5: 1.0000
2026-01-18 13:02:16,697 - INFO - Test MRR@5      : 1.0000
2026-01-18 13:02:16,697 - INFO - Prediction files written to publication folders
2026-01-18 13:02:16,697 - INFO - Pipeline completed successfully
```

Kết quả chi tiết trên các tập Validation và Test:

Tập dữ liệu	Publication ID	Số cặp mẫu	MRR@5	Hits (Top-5)	Đánh giá
Test	2412-20155	20	**0.8875**	**19/20**	**Rất tốt**
Validation	2412-20242	30	0.0500	2/30	Cần cải thiện

Nhận xét:

- Trên tập Test (2412-20155 - Chủ đề Optimization/ML), mô hình đạt kết quả ấn tượng với MRR ~0.89 và tìm thấy chính xác 19/20 tham chiếu. Điều này chứng minh bộ đặc trưng (Feature Set) hoạt động hiệu quả trên các bài báo có cấu trúc trích dẫn tiêu chuẩn.
- Trên tập Validation (2412-20242 - Chủ đề High Energy Physics), hiệu năng giảm sút (MRR 0.05). Nguyên nhân được xác định do sự khác biệt lớn về phong cách trích dẫn trong lĩnh vực Vật lý năng lượng cao so với tập huấn luyện, dẫn đến hiện tượng "Domain Shift".

4. Đánh giá khả năng mở rộng

Em đã triển khai pipeline trên tập dữ liệu 500 bài báo (Auto Subset) để kiểm tra tính ổn định.

- **Quy mô:** 500 bài báo.
- **Thời gian thực thi:** ~5.41 giây (Batch processing).
- **Kết quả ghi nhận:**
  - Validation MRR@5: 1.0000
  - Test MRR@5: 1.0000

Lý giải về điểm số tuyệt đối (1.0):

Kết quả MRR = 1.0 trên tập dữ liệu tự động (Auto Subset) không phản ánh khả năng tổng quát hóa trên dữ liệu thực tế, mà phản ánh sự hội tụ hoàn hảo của mô hình đối với thuật toán gán nhãn Heuristic. Nói cách khác, mô hình Gradient Boosting đã học thành công quy luật gán nhãn tự động mà em thiết lập (dựa trên Title Matching và Author Overlap). Điều này xác nhận rằng pipeline hoạt động chính xác về mặt logic và không có lỗi kỹ thuật (bugs) khi xử lý dữ liệu lớn.

D. THỰC HÀNH – DEMO

Link video: [VIDEO DEMO LAB 2 MODELLING]